

CERTIFICAT DE SPÉCIALISATION ANALYSTE DE DONNÉES MASSIVES

Entreposage et fouille de données

Projet de STA211

Auteurs:

Boukary OUEDRAOGO

Bangaly CAMARA

Imad EL HAMMA

Professeur:

Mme Niang

2021-2022

 $U(x) \approx U_h = \sum_{j=1}^{N} c_j \varphi_j(x)$

$$u''(x_i) \approx \frac{1}{h^2} [u(x_{i+1}) - 2u(x_i) + u(x_{i-1})]$$

Résumé

Dans le cadre de ce projet blabla blabla blabla

1. Introduction

2. Chargement des données et analyses préliminaires

Cette partie est consacrée au chargement des données et à la sélection des variables liées au ménage. Certaines variables qui sont codées comme des variables numériques mais qui en réalité sont qualitatives seront recordées en variables facteurs.

2.1 Chargement des données

Après le chargement des données, l'étape suivante est l'analyse univariée. On peut regarder les statistiques descriptives simples avec la function **summary** et la fonction **describe**.

```
##
    Sexe
               Diplome_Max
                             Type_Prof Occupation Source_ppale_Res Structure_menage
##
    1: 549
              4
                      :454
                             1: 36
                                        1:777
                                                    1:845
                                                                       1: 398
    2:1018
                      :175
                             2: 70
                                        2: 80
                                                    2: 87
                                                                       2: 103
##
              8
##
              1
                      :171
                             3:435
                                        3: 50
                                                    3:493
                                                                       3:1053
##
              9
                      :168
                             4:391
                                        4:541
                                                    4: 71
                                                                       4:
                                                                           13
              6
                      :157
                             5:297
                                        5: 45
                                                    5: 71
              5
##
                      :137
                             6:316
                                        6: 74
              (Other):305
                             7: 22
##
         Age
                         Revenus
                                         TYPEMEN
                                                       Nb_Enfants_sup_10
            :18.00
                                              :1.000
##
    Min.
                     Min.
                             : 535
                                      Min.
                                                       Min.
                                                               :0.0000
    1st Qu.:41.00
                     1st Qu.:1799
                                      1st Qu.:3.000
                                                        1st Qu.:0.0000
##
                     Median:2349
                                      Median :5.000
    Median :52.00
                                                       Median :0.0000
##
            :51.87
                             : 2573
##
    Mean
                     Mean
                                      Mean
                                              :4.754
                                                       Mean
                                                               :0.4359
    3rd Qu.:61.50
                     3rd Qu.:2899
                                      3rd Qu.:7.000
                                                       3rd Qu.:1.0000
##
##
    Max.
            :89.00
                     Max.
                             :7600
                                      Max.
                                              :7.000
                                                       Max.
                                                               :3.0000
##
##
    Nb_Enfants_inf_10
##
    Min.
            :0.0000
##
    1st Qu.:0.0000
    Median :0.0000
##
##
    Mean
            :0.3165
```

```
##
   Max.
         :3.0000
##
## Description of .
##
   Numeric
##
##
                     mean median min max
                                           var
                                                        sd
## Age
                     51.87
                              52 18
                                      89
                                             209.91
                                                     14.49
                            2349 535 7600 1967644.23 1402.73
## Revenus
                   2573.20
                     4.75
                                       7
## TYPEMEN
                               5
                                   1
                                               4.55
                                                      2.13
## Nb_Enfants_sup_10 0.44
                               0
                                   0
                                       3
                                              0.67
                                                      0.82
## Nb_Enfants_inf_10 0.32
                               0
                                   0
                                       3
                                               0.48
                                                      0.70
##
##
   Factor
##
## Sexe
                 2
                       1
           1018.00 549.00
##
    Count
    Percent 64.96 35.04
##
## Mode 2
##
## Diplome_Max 4
                        8
                               1
                                     9
                                            6
                                                 5
                                                         7
                                                                     2
                                                               3
             454.00 175.00 171.00 168.00 157.00 137.00 132.00 117.00 56.00
##
      Percent 28.97 11.17 10.91 10.72 10.02 8.74 8.42
                                                            7.47 3.57
## Mode 4
##
                3
                  4 6
                                   5
                                         2
                                              1
## Type_Prof
           435.00 391.00 316.00 297.00 70.00 36.0 22.0
    Percent 27.76 24.95 20.17 18.95 4.47 2.3 1.4
## Mode 3
##
## Occupation 1 4
                             2
                                   6
            777.00 541.00 80.00 74.00 50.00 45.00
##
     Percent 49.59 34.52 5.11 4.72 3.19 2.87
##
## Mode 1
##
```

3rd Qu.:0.0000

##

Source_ppale_Res 2 5 1 3 Count 845.00 493.00 87.00 71.00 71.00 Percent 53.92 31.46 5.55 4.53 4.53 ## Mode 1 ## 1 2 ## Structure_menage 3 4 Count 1053.0 398.0 103.00 13.00 ## Percent 67.2 25.4 6.57 0.83 ## Mode 3

2.2 Analyse descriptive des variables quantitatives

2.2.1 Analyse univarié

Variables	Moyenne	Médiane	Min	Maximum	Variance	Ecart-type
Age	51.87	52	18	89	209.91	14.49
Revenus	2 573.20	2 349	535	7 600	1 967 644.23	1 402.73
Nombre d'enfants dont âge > 10 ans	0.44	0	0	3	0.67	0.82
Nombre d'enfants dont âge <= 10 ans	0.32	0	0	3	0.48	0.70

 ${\tt TABLE}\ 1-{\tt Statistiques}\ descriptives\ des\ variables\ quantitatives$

2.2.2 Analyse bivariée : Etudes des liaisons entre les différentes variables quantitatives





