

CERTIFICAT DE SPÉCIALISATION ANALYSTE DE DONNÉES MASSIVES

Entreposage et fouille de données

Projet de STA211

Auteurs:

Professeur:

Boukary OUEDRAOGO

Mme Niang

Bangaly CAMARA

Imad EL HAMMA

2021-2022

$$A_{m,n} = \begin{pmatrix} a_{l,1} & a_{l,2} & \dots & & & \\ a_{2,1} & a_{2,2} & \dots & a_{l,n} \\ \vdots & \vdots & \ddots & a_{2,n} \\ a_{m,1} & a_{m,2} & \dots & \vdots \\ & & & & & \\ & & & & \\ & & & & \\ & & & & \\ & & & & \\ & & & & \\ & & & & \\ & & &$$

$$u''(x_i) \approx \frac{1}{h^2} \left[u(x_{i+1}) - 2u(x_i) + u(x_{i-1}) \right]$$

Analyse univariée

Dans cette partie nous allons explorer les données en réalisant des analyses univariées simples. Nous regarderons les statistiques descriptives simples de chacune des variables, puis nous effectuerons des

Analyse univarié simple avec summary

```
summary(data_menage)
```

```
Type_Prof Occupation Source_ppale_Res Structure_menage
##
   Sexe
              Diplome_Max
                     :454
                            1: 36
                                       1:777
                                                  1:845
                                                                     1: 398
##
    1: 549
##
   2:1018
             8
                     :175
                            2: 70
                                       2: 80
                                                  2: 87
                                                                     2: 103
                     :171
                            3:435
                                       3: 50
                                                  3:493
                                                                     3:1053
##
             1
##
             9
                     :168
                            4:391
                                       4:541
                                                  4: 71
                                                                     4: 13
##
             6
                     :157
                            5:297
                                       5: 45
                                                  5: 71
             5
                                       6: 74
##
                     :137
                            6:316
##
             (Other):305
                            7: 22
##
                        Revenus
                                        TYPEMEN
                                                      Nb_Enfants_sup_10
         Age
           :18.00
##
    Min.
                     Min.
                            : 535
                                     Min.
                                            :1.000
                                                      Min.
                                                             :0.0000
    1st Qu.:41.00
                     1st Qu.:1799
                                     1st Qu.:3.000
                                                      1st Qu.:0.0000
##
   Median :52.00
                    Median:2349
                                     Median :5.000
                                                     Median :0.0000
##
##
   Mean
           :51.87
                     Mean
                            :2573
                                     Mean
                                            :4.754
                                                     Mean
                                                             :0.4359
    3rd Qu.:61.50
                     3rd Qu.:2899
                                     3rd Qu.:7.000
                                                      3rd Qu.:1.0000
##
           :89.00
                            :7600
                                            :7.000
##
   Max.
                     Max.
                                     Max.
                                                      Max.
                                                             :3.0000
##
##
    Nb_Enfants_inf_10
           :0.0000
##
   Min.
    1st Qu.:0.0000
##
   Median :0.0000
##
           :0.3165
##
   Mean
    3rd Qu.:0.0000
##
           :3.0000
##
   Max.
##
```

```
data_menage %>%
  describe()
## Description of .
##
##
   Numeric
##
                        mean median
                                                     sd valid.n
                                           var
## Age
                       51.87
                                 52
                                        209.91
                                                  14.49
                                                           1567
## Revenus
                     2573.20
                               2349 1967644.23 1402.73
                                                           1567
## TYPEMEN
                        4.75
                                  5
                                          4.55
                                                   2.13
                                                           1567
## Nb_Enfants_sup_10
                        0.44
                                  0
                                          0.67
                                                   0.82
                                                           1567
## Nb_Enfants_inf_10
                        0.32
                                          0.48
                                                   0.70
                                  0
                                                           1567
##
   Factor
##
##
## Sexe
                   2
             1018.00 549.00
##
    Count
##
    Percent
               64.96 35.04
## Mode 2
##
## Diplome_Max
                           8
                                  1
                                         9
                                                6
                                                        5
                                                               7
                                                                      3
                                                                            2
               454.00 175.00 171.00 168.00 157.00 137.00 132.00 117.00 56.00
##
       Count
       Percent 28.97 11.17 10.91 10.72 10.02
                                                    8.74
                                                            8.42
                                                                   7.47 3.57
## Mode 4
##
                                             2
## Type_Prof
                  3
                                6
                                       5
             435.00 391.00 316.00 297.00 70.00 36.0 22.0
##
     Count
##
    Percent 27.76 24.95 20.17 18.95 4.47 2.3 1.4
## Mode 3
##
## Occupation
                   1
                          4
                                2
                                      6
##
              777.00 541.00 80.00 74.00 50.00 45.00
      Percent 49.59 34.52 5.11 4.72 3.19 2.87
##
## Mode 1
##
## Source_ppale_Res
                         1
                                3
```

845.00 493.00 87.00 71.00 71.00

##

Count

Dans cette partie, on sépare le jeu de données initiales en deux. Une partie contenant les variables catégorielles et une partie contenant les variables numériques.

```
num_cols <- unlist(lapply(data_menage, is.numeric))</pre>
cat_col <- unlist(lapply(data_menage, is.character))</pre>
num_data <- data_menage[, num_cols]</pre>
cat_data <- data_menage[,cat_col]</pre>
data_hist <- num_data %>%
  gather(key="text", value="value") %>%
  mutate(text = gsub("\\.", "-",text)) %>%
  mutate(value = round(as.numeric(value),0))
# p <- data_hist %>%
    mutate(text = fct_reorder(text, value)) %>%
    qqplot( aes(x=value, color=text, fill=text)) +
#
      geom_histogram(alpha=0.6, binwidth = 5) +
#
     # scale_fill_viridis(discrete=TRUE) +
#
     # scale_color_viridis(discrete=TRUE) +
#
      theme_ipsum() +
#
      theme(
#
#
        legend.position="none",
        panel.spacing = unit(0.1, "lines"),
#
#
        strip.text.x = element_text(size = 8)
      ) +
#
      xlab("") +
#
      facet_wrap(~text)
# p
```

Les corrélations entre les variables numériques sont faibles dans la majorité des cas.

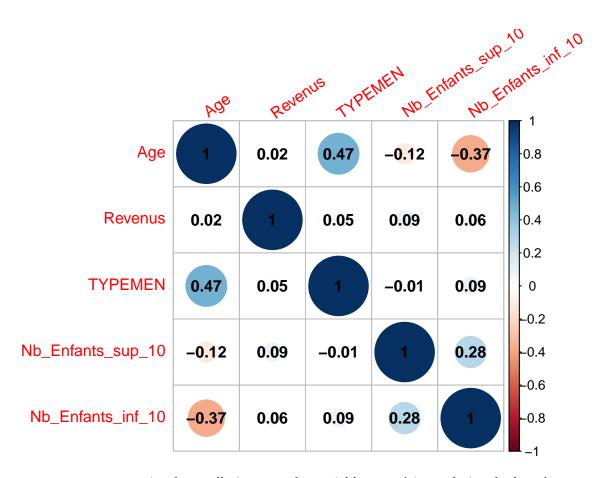


FIGURE 1 – Matrice de corrélation entre les variables numériques du jeu de données