

CERTIFICAT DE SPÉCIALISATION ANALYSTE DE DONNÉES MASSIVES

## Entreposage et fouille de données

## Projet de STA211

Auteurs:

Professeur:

**Boukary OUEDRAOGO** 

**Mme Niang** 

**Bangaly CAMARA** 

Imad EL HAMMA

2021-2022

$$A_{m,n} = \begin{pmatrix} a_{l,1} & a_{l,2} & \dots & & & \\ a_{2,1} & a_{2,2} & \dots & a_{l,n} \\ \vdots & \vdots & \ddots & a_{2,n} \\ a_{m,1} & a_{m,2} & \dots & \vdots \\ & & & & & \\ & & & & \\ & & & & \\ & & & & \\ & & & & \\ & & & & \\ & & & & \\ & & &$$

$$u''(x_i) \approx \frac{1}{h^2} \left[ u(x_{i+1}) - 2u(x_i) + u(x_{i-1}) \right]$$

## Introduction

Dans cette partie nous allons explorer les données en réalisant des analyses univariées simples. Nous regarderons les statistiques descriptives simples de chacune des variables, puis nous effectuerons des

# Analyse univarié simple avec summary

```
summary(data_menage)
```

```
Sexe
              Diplome_Max
                           Type_Prof Occupation Source_ppale_Res Structure_menage
##
   1: 549
                    :454
                           1: 36
                                      1:777
                                                 1:845
                                                                   1: 398
##
##
   2:1018
             8
                    :175
                           2: 70
                                      2: 80
                                                 2: 87
                                                                   2: 103
##
             1
                    :171
                           3:435
                                      3: 50
                                                 3:493
                                                                   3:1053
##
             9
                    :168
                           4:391
                                     4:541
                                                 4: 71
                                                                   4: 13
##
             6
                    :157
                           5:297
                                      5: 45
                                                 5: 71
             5
                    :137
                           6:316
                                      6: 74
##
             (Other):305
                           7: 22
##
                                       TYPEMEN
                                                    Nb_Enfants_sup_10
##
         Age
                       Revenus
##
   Min.
           :18.00
                    Min.
                           : 535
                                    Min.
                                           :1.000
                                                    Min.
                                                            :0.0000
   1st Qu.:41.00
                    1st Qu.:1799
                                    1st Qu.:3.000
                                                    1st Qu.:0.0000
##
                    Median :2349
   Median :52.00
                                   Median :5.000
                                                    Median :0.0000
##
           :51.87
##
   Mean
                    Mean
                           :2573
                                   Mean :4.754
                                                    Mean
                                                           :0.4359
    3rd Qu.:61.50
                                                    3rd Qu.:1.0000
                    3rd Qu.:2899
                                    3rd Qu.:7.000
##
           :89.00
                    Max.
                           :7600
                                           :7.000
                                                           :3.0000
##
   Max.
                                   Max.
                                                    Max.
##
##
   Nb_Enfants_inf_10
           :0.0000
##
   Min.
   1st Qu.:0.0000
##
   Median :0.0000
##
           :0.3165
##
   Mean
##
   3rd Qu.:0.0000
##
   Max.
           :3.0000
##
```

```
data_menage %>%
  describe()
## Description of .
##
##
   Numeric
##
                        mean median
                                                     sd valid.n
                                           var
## Age
                       51.87
                                 52
                                        209.91
                                                  14.49
                                                           1567
## Revenus
                     2573.20
                               2349 1967644.23 1402.73
                                                           1567
## TYPEMEN
                        4.75
                                  5
                                          4.55
                                                   2.13
                                                           1567
## Nb_Enfants_sup_10
                        0.44
                                  0
                                          0.67
                                                   0.82
                                                           1567
## Nb_Enfants_inf_10
                        0.32
                                          0.48
                                                   0.70
                                  0
                                                           1567
##
   Factor
##
##
## Sexe
                   2
             1018.00 549.00
##
    Count
##
    Percent
               64.96 35.04
## Mode 2
##
## Diplome_Max
                           8
                                  1
                                         9
                                                6
                                                        5
                                                               7
                                                                      3
                                                                            2
               454.00 175.00 171.00 168.00 157.00 137.00 132.00 117.00 56.00
##
       Count
       Percent 28.97 11.17 10.91 10.72 10.02
                                                    8.74
                                                            8.42
                                                                   7.47 3.57
## Mode 4
##
                                             2
## Type_Prof
                  3
                                6
                                       5
             435.00 391.00 316.00 297.00 70.00 36.0 22.0
##
     Count
##
    Percent 27.76 24.95 20.17 18.95 4.47 2.3 1.4
## Mode 3
##
## Occupation
                   1
                          4
                                2
                                      6
##
              777.00 541.00 80.00 74.00 50.00 45.00
      Percent 49.59 34.52 5.11 4.72 3.19 2.87
##
## Mode 1
##
## Source_ppale_Res
                         1
                                3
```

845.00 493.00 87.00 71.00 71.00

##

Count

Dans cette partie, on sépare le jeu de données initiales en deux. Une partie contenant les variables catégorielles et une partie contenant les variables numériques.

```
num_cols <- unlist(lapply(data_menage, is.numeric))</pre>
cat_col <- unlist(lapply(data_menage, is.character))</pre>
num_data <- data_menage[, num_cols]</pre>
cat_data <- data_menage[,cat_col]</pre>
data_hist <- num_data %>%
  gather(key="text", value="value") %>%
  mutate(text = gsub("\\.", "-",text)) %>%
  mutate(value = round(as.numeric(value),0))
# p <- data_hist %>%
    mutate(text = fct_reorder(text, value)) %>%
    qqplot( aes(x=value, color=text, fill=text)) +
#
      geom_histogram(alpha=0.6, binwidth = 5) +
#
     # scale_fill_viridis(discrete=TRUE) +
#
     # scale_color_viridis(discrete=TRUE) +
#
      theme_ipsum() +
#
      theme(
#
#
        legend.position="none",
        panel.spacing = unit(0.1, "lines"),
#
#
        strip.text.x = element_text(size = 8)
      ) +
#
      xlab("") +
#
      facet_wrap(~text)
# p
```

Les corrélations entre les variables numériques sont faibles dans la majorité des cas.

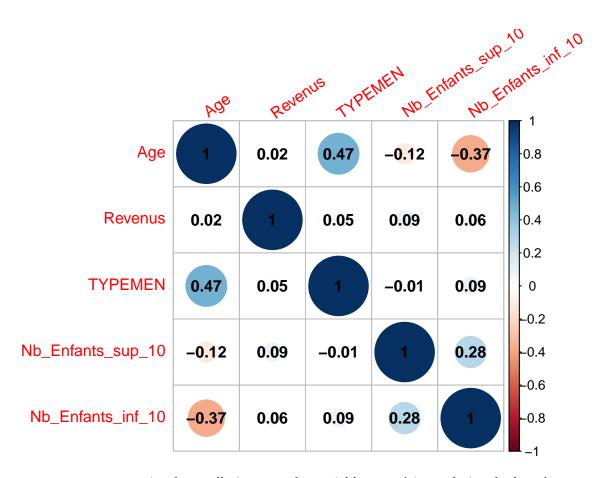


FIGURE 1 – Matrice de corrélation entre les variables numériques du jeu de données